

Modelo para Classificação Fitopatológica em Vegetais *Phaseolus Vulgaris*

Igor Gonçalves de Souza
Ítalo Augusto de Sousa Tacca

2023/2

Problemática

- A agricultura brasileira movimentou mais de 60 bilhões de dólares em exportações no ano de 2022;
- Pragas e outras doenças podem causar reduções de até 30% na produtividade;
- A perda de produtividade gera inflação alimentar e outros impactos significativos;
- Baixa utilização de tecnologia no setor;
- Modelo de análise da saúde de plantas.

Trabalhos Relacionados

| Autor | Descrição | Modelo | Acurácia |
|-------------------------|--|-----------------------------------|----------|
| Chen et al. [5] | Classificação de doenças nas folhas de chá | CNN | 90,16% |
| Liu et al. [6] | Classificação de doenças nas folhas da maçã | CNN | 97,62% |
| Liang et al. [7] | Classificação de doenças nas folhas do arroz | CNN | 95,83% |
| Zaki et al. [8] | Classificação de doenças no tomate | Transfer Learning MobileNet V2 | 90% |
| Vinutha et al. [9] | Classificação de doenças em múltiplas espécies (8) | Transfer Learning MobileNet V2 | 99% |
| E. Elfatimi et al. [10] | Classificação de doenças nas folhas do feijão | Transfer Learning MobileNet V2 | 92,97% |

Metodologia: *Dataset Beans*

- Conjunto com 1.167 imagens de feijões;
- 3 classes: Saudável, Mancha Angular da Folha e Ferrugem do Feijão.



Mancha Angular



Ferrugem

Metodologia: *Edge Impulse*

- Plataforma de desenvolvimento para sistemas de aprendizado de máquina embarcado;
- Aquisição de dados em dispositivos como câmera, acelerômetro e microfone para treinamento;
- Interface para treinamento do modelo;
- Implementação em dispositivos de borda;
- Desempenho e classificação do modelos em tempo real;
- Algoritmo de otimização para encontrar o melhor modelo para a aplicação.

Metodologia: *EON Tuner*

- Otimização hiper paramétrica com *EON Tuner*;
- *Transfer Learning*: técnica que envolve o uso de modelos pré-treinados e adaptados para novas tarefas relacionadas;
- Não se treina o modelo do zero;
- Aproveita-se o conhecimento adquirido por um modelo em uma tarefa anterior;
- Modelo mais eficiente e melhor desempenho em conjuntos de dados menores;
- Ajuste fino e extração de características.

Metodologia: *Dropout*

- Técnica de regularização para combater o sobre ajuste;
- Descarte aleatório de neurônios em uma camada durante o treinamento;
- Problema de classificação de imagens.


Metodologia: CNNs

- Processamento de dados em grade: reconhecimento de imagens e detecção de objetos;
- Camadas convolucionais e de *pooling*;
- Camadas densas;
- Funções de ativação: não linearidade na rede e relações mais complexas nos dados.

Metodologia: MobileNetV2

- Redes neurais convolucionais para aplicações de visão computacional;
- Imagens de tamanho 32x32;
- Oferecendo melhor desempenho com tamanhos maiores;
- Blocos residuais invertidos com características de gargalo e valor mais baixo para contagem de parâmetros.


Metodologia: MobileNetV2



- Camada intermediária usa convoluções para filtrar características;
- Arquitetura com camada inicial de convolução com 32 filtros seguida por 19 camadas de gargalo residual.

Dados de Treinamento

- Features:



Modelo de Rede Neural

- Obtido por *Transfer Learning*;
- Busca com o EON *Tuner*.



| Modelo | Acurácia |
|-------------------------------|----------|
| RGB – MobileNetV2 - 686 | 87% |
| Grayscale – MobileNetV2 – 8a4 | 82% |
| RGB – MobileNetV2 – 9b9 | 76% |

Modelo de Rede Neural

- Acrescentou-se ao modelo MobileNetV2 uma camada densa final com 64 neurônios;
- Definiu-se o *dropout* como 0,5.

Treinamento: Conjunto de Dados


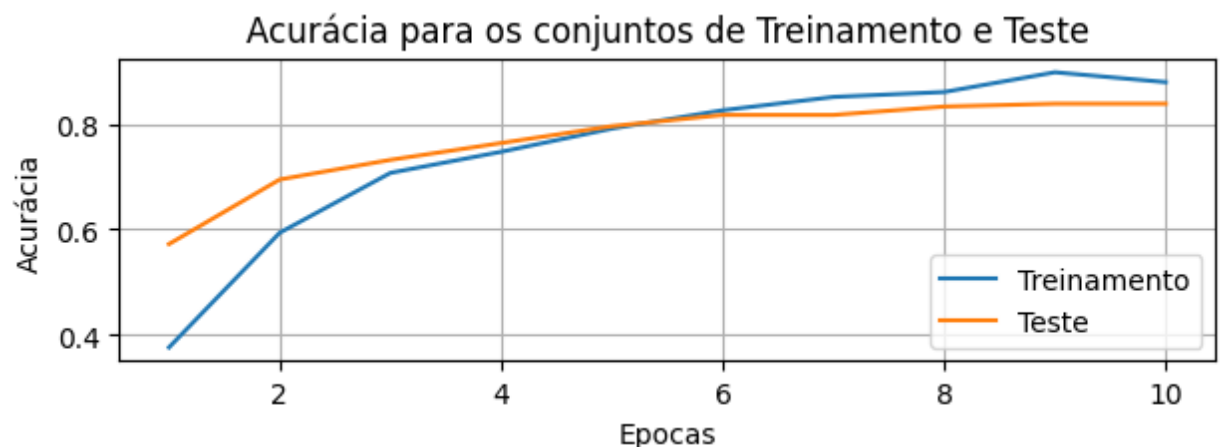
- O *Dataset Beans* foi dividido em 80% para treinamento e 20% para testes.



Treinamento

- Treinamento por 10 épocas;
- Taxa de aprendizagem: 0,0005;
- Fator proporcional para o número de filtros: $\alpha = 0,35$;
- Tamanho de batch: 32;
- *Data Augmentation* (Plataforma).

Resultados: Acurácia e Perda



Resultados: Matriz de Confusão

| Métrica | Treinamento | Teste (32 bits) | Teste (8 bits) |
|----------|-------------|-----------------|----------------|
| Acurácia | 91,42% | 88,8% | 87,2% |
| Perda | 0,24 | 0,36 | 0,40 |

MATRIZ DE CONFUSÃO DO MODELO QUANTIZADO.

| | Manchadas | Ferrugem | Saudável |
|-----------|-----------|----------|----------|
| Manchadas | 85,0% | 11,7% | 3,3% |
| Ferrugem | 13,5% | 85,1% | 1,4% |
| Saudável | 5,7% | 1,9% | 92,5% |
| F1 Score | 0.82 | 0.87 | 0.93 |

$$\frac{85,0 + 85,1 + 92,5}{3} = 87,5\%$$

Resultados: Matriz de Confusão

| Métrica | Treinamento | Teste (32 bits) | Teste (8 bits) |
|----------|-------------|-----------------|----------------|
| Acurácia | 91,42% | 88,8% | 87,2% |
| Perda | 0,24 | 0,36 | 0,40 |


MATRIZ DE CONFUSÃO DO MODELO NÃO QUANTIZADO.

| | Manchadas | Ferrugem | Saudável |
|-----------|-----------|----------|----------|
| Manchadas | 81,7% | 15,0% | 3,3% |
| Ferrugem | 8,1% | 90,5% | 1,4% |
| Saudável | 3,8% | 1,9% | 94,3% |
| F1 Score | 0.84 | 0.89 | 0.94 |

$$\frac{81,7 + 90,5 + 94,3}{3} = 88,8\%$$

Resultados: *Data Explorer*

- angular_leaf_spot - correct
- angular_leaf_spot - incorrect
- bean_rust - correct
- bean_rust - incorrect
- healthy - correct
- healthy - incorrect



Aplicação Prática: Descrição

- Monitoramento de Saúde de Culturas Agrícolas via Drones;
- Câmeras em drones para filmar e avaliar as condições das folhas das plantas;
- Sobrevoos e cobertura da área cultivada;
- Identificação de doenças e tomada de ações preventivas.

Aplicação Prática: Processamento

- Processadas pelo modelo treinado;
- Reconhecimento de Ferrugem do Feijão e “Mancha Angular da Folha” nas folhas;
- Áreas específicas com sinais de doenças.

Aplicação Prática: Benefícios

- Detecção precoce de doenças;
- Intervenções rápidas;
- Reduz a propagação de doenças e perdas nas colheitas;
- Economia de recursos.

Conclusão

- Desafios de aumento da produtividade das safras;
- Aprendizagem de máquina é essencial para o desenvolvimento de ferramentas para combater esses problemas;
- Baixo uso de recursos computacionais;
- Acurácia satisfatória: demonstrando potencial para aplicações de classificação de doenças que auxiliem o aumento da produtividade das safras.

Inatel

Instituto Nacional de Telecomunicações

www.inatel.br

A photograph of a two-story orange building with a central entrance and palm trees in the foreground. The building has multiple windows and a balcony. The foreground is a grassy area with some low-lying plants. The sky is blue with some clouds.

Obrigado!